

Apresentação — como os experimentos foram feitos

Datasets

Dois corpora, escolhidos porque carregam **confundidores distintos** entre identidade do locutor e condição de gravação. Não são duas réplicas do mesmo experimento.

	BrSD	VCTK 0.92
Locutores (corpus / usados)	80 / 80	110 / 108
Gravações por locutor (usadas)	5	~400 (200)
Total de gravações	400	21.523 por trilha
Duração por gravação	16 s a 1 min 56 s (mediana 29 s)	poucos segundos
Texto	dependente (mesmos 5 textos)	independente
Microfones	um por locutor (aparelho próprio)	dois, simultâneos
Taxa / formato	48 kHz · WMA, com perda	48 kHz · FLAC, sem perda
Licença	não declarada ("freely available")	CC BY 4.0
Obtenção	sites.google.com/view/brsduem	DOI 10.7488/ds/2645
Acaso (1/N)	1,25%	0,93%

O confundidor do BrSD: um dispositivo por locutor. Cada pessoa gravou no próprio celular, em ambiente não controlado. A assinatura de canal — resposta em frequência, ruído de fundo, ganho, codec — é constante dentro do locutor e distinta entre locutores, ou seja, **um identificador perfeito da pessoa, sem voz nenhuma**. Nenhuma partição corrige isso: conjunto fechado exige o locutor nos dois lados, logo o aparelho dele também aparece nos dois.

O confundidor do VCTK: sessão. Mesma sala e mesmo equipamento para todos, então o modelo do microfone deixa de prever o rótulo, e o texto é independente. Mas cada locutor foi gravado em **uma única sessão**: ganho do dia, distância e postura, respiração. O confundidor muda de *dispositivo* para *sessão*, a estrutura é a mesma. Em compensação, as duas trilhas gravam a mesma frase ao mesmo tempo — voz, texto e instante idênticos, só o transdutor muda —, e é isso que viabiliza os protocolos **cross-microfone** (treinar numa trilha, avaliar na outra) e **multi-microfone**.

Por que 108 e não 110. p280 e p315 não têm trilha mic2, e ocupam as posições 54 e 84 da ordenação. Numerando cada trilha isoladamente, tudo a partir da 54 desloca em um: **57 dos 110 locutores recebiam rótulo trocado**, e o teto de acurácia era **48,2%**, não 100% — foi contra esse teto que os 24,09% anteriores foram medidos. A numeração passou a sair da **interseção** das trilhas; alinhamento verificado depois, com recuperação do par correto **100/100** entre 20 distratores.

O BrSD é distribuído em WMA, codec com perda, a montante de tudo e irreversível. É o mesmo codec para todos, logo não distingue locutores por si — mas a interação entre codec e canal distingue, porque aparelhos diferentes levam o encoder a alocar bits de formas diferentes. É mais uma camada da assinatura de canal.

Atribuição. VCTK: Yamagishi, Veaux & MacDonald (2019), *CSTR VCTK Corpus* v0.92. BrSD: Paulino, M. A et al., *A Brazilian Speech Database*, ICTAI 2018 — sem licença declarada: uso acadêmico, sem redistribuição, a confirmar com os autores.

Pré-processamento — do sinal bruto aos MFCCs

Cadeia canônica, na ordem exata em que `sr/preprocessing/pipeline.py` a executa:


carregar → [VAD] → anti-aliasing → decimação → pré-ênfase → janelamento → mel → log → DCT

As figuras abaixo saem de **uma gravação real percorrendo as mesmas funções do pipeline** (`figuras_cadeia.py` chama `sr.preprocessing.signal`, não reimplementa nada). O perfil ilustrado é `brsd_vad.env`, cuja cadeia é idêntica à do perfil de referência do VCTK; o perfil de referência do BrSD difere só em taxa de destino (8 kHz) e janela (256 amostras).

parâmetro	BrSD ref.	BrSD/VCTK 16 kHz	onde
Taxa de origem	48 kHz	48 kHz	<code>SOURCE_SAMPLING_RATE</code>
Taxa de destino	8 kHz	16 kHz	<code>TARGET_SAMPLING_RATE</code>
VAD	desligado	ligado, 30 dB	<code>ENABLE_VAD</code> , <code>VAD_TOP_DB</code>
Ordem do anti-aliasing	8	8	<code>ANTIALIAS_ORDER</code>
Corte do anti-aliasing	3,6 kHz	7,2 kHz	$0,45 \times \text{Nyquist do destino}$
Pré-ênfase	0,97	0,97	<code>PRE_EMPHASIS_COEF</code>
Janela	256 (32 ms)	512 (32 ms)	<code>FRAME_SIZE</code>
Salto	128 (16 ms)	256 (16 ms)	<code>FRAME_SIZE / 2</code>
Coeficientes	40	40	<code>NUM_MFCCS</code>

1. Carregamento

`librosa.load(caminho, sr=48000)` — devolve **mono, float32, escala cheia em $[-1, +1]$** . A conversão para mono e a reamostragem para 48 kHz acontecem aqui, o que uniformiza os arquivos heterogêneos do BrSD. Nenhum ganho é aplicado: a amplitude é adimensional e não corresponde a pressão sonora, então só diferenças **relativas** dentro da mesma gravação têm sentido físico.




Gravação de 68,7 s (3.295.729 amostras). No espectro, note o corte abrupto em 20 kHz: é o codec WMA do BrSD, não o nosso processamento — o corpus já chega com a banda superior removida.

2. Detecção de atividade vocal (VAD)

`librosa.effects.split(audio, top_db=30)`, com os defaults da biblioteca: `frame_length=2048` (**42,7 ms** a 48 kHz), `hop_length=512` (**10,7 ms**), referência e agregação pelo **máximo**. Mantém os intervalos cuja energia fique a menos de 30 dB abaixo do pico, e **concatena** — a saída não preserva a linha do tempo original.

O complemento exato dessa operação (`extract_silence`) é o **controle negativo** do trabalho: se a identidade do locutor for predita a partir do que o VAD jogou fora, ela não está sendo lida da voz.




Nesta gravação o VAD encontra 129 intervalos com voz e retém 37,7% das amostras: 68,7 s viram 25,9 s, e 42,8 s são descartados. O painel de baixo mantém a mesma escala de tempo para tornar o encurtamento visível. "Silêncio" aqui é o complemento de um detector de energia, não uma anotação de ausência de fala: pode conter respiração e fala fraca.

3. Filtro anti-aliasing

Butterworth passa-baixas de **ordem 8**, corte em **$0,45 \times$ Nyquist do destino** — 7,2 kHz para destino de 16 kHz. Aplicado com `sosfiltfilt`, que filtra para frente e para trás: a fase resultante é **exatamente nula** e a magnitude é elevada ao quadrado, dobrando a atenuação em dB.

A filtragem de fase zero não é preciosismo. A filtragem direta introduz atraso de fase dependente da frequência, que desloca os formantes uns em relação aos outros ao longo do tempo — e a análise cepstral registraria esse deslocamento como se fosse propriedade do sinal.

frequência	1 passagem	efetivo (<code>sosfiltfilt</code>)
7,2 kHz (corte)	−3,0 dB	−6,0 dB
8,0 kHz (Nyquist do destino)	−9,2 dB	−18,5 dB
9,0 kHz	−18,9 dB	−37,8 dB
12,0 kHz	−46,9 dB	−93,7 dB




A declarar com honestidade: em 8 kHz a atenuação é de apenas $-18,5$ dB, então conteúdo logo acima do Nyquist do destino ainda rebateria com essa supressão. A proteção principal vem do próprio `resample_poly`, que aplica um FIR de Kaiser interno; o Butterworth é o pré-filtro com banda de guarda.

4. Decimação

`resample_poly` — reamostragem **polifásica** por razão racional exata ($48/16 = 3$; $48/8 = 6$). Não se usa o método por FFT porque ele pressupõe periodicidade do sinal e produz artefatos nas bordas de gravações que não começam e terminam no mesmo valor.


A banda útil passa a ser **0 a 8 kHz** (ou 0 a 4 kHz no perfil de 8 kHz). O custo é declarado: descarta-se a região onde reside parte da informação de locutor — fricativas, formantes altos, detalhes da fonte glotal.



5. Pré-ênfase

FIR de primeira ordem, $y[n] = x[n] - 0,97 \cdot x[n-1]$, ou seja $H(z) = 1 - 0,97 z^{-1}$. Passa-altas suave, de aproximadamente **+6 dB por oitava**, que compensa a queda espectral da fala e equilibra a energia entre as regiões grave e aguda antes da análise cepstral.


Vem depois da decimação, e não antes. É um filtro definido em relação à taxa de amostragem final: aplicá-lo a 48 kHz colocaria o ponto de corte em outro lugar do espectro que não o pretendido.



6. Janelamento

Janela de **Hann**, 512 amostras = **32 ms**, salto de 256 = **16 ms**, portanto 50% de sobreposição. A duração é a convencional em análise de fala: longa o bastante para conter vários períodos de pitch, curta o bastante para que o sinal seja aproximadamente estacionário dentro dela. O perfil de 8 kHz usa 256 amostras, preservando os mesmos 32 ms.

O `librosa` usa `center=True` com preenchimento por zeros, de modo que o número de quadros é $1 + \lfloor N/\text{salto} \rfloor$ — nesta gravação, as 414.208 amostras que sobram após a decimação produzem **1.619 quadros**.




7. Mel, logaritmo e DCT — a extração


Sobre cada quadro: espectrograma de **potência** (`power=2.0`), projetado em **128 filtros mel triangulares** na escala Slaney, normalizados por área. O resultado vai para dB (`power_to_db`),

referência 1,0, piso 80 dB abaixo do pico de cada gravação) e sofre uma **DCT-II ortonormal**, da qual se retêm os **40 primeiros** coeficientes. Sem liftering (`lifter=0`).

Os 40 coeficientes estão bem acima dos 13 a 20 usuais, e a consequência precisa ser declarada: com 40, a DCT descarta pouca informação e o vetor se aproxima do log-espectro mel completo. Os coeficientes de ordem alta descrevem estrutura espectral fina — harmônicos, pitch e **coloração do canal** —, não apenas o envelope do trato vocal. Aumentar o número de coeficientes aumenta simultaneamente a informação de voz e a de equipamento disponíveis ao classificador.



Coeficientes 1 a 39 — matriz completa é 40×1619 (coeficientes $\times$ quadros), 25.9 s; cores saturadas no percentil 99



Saída final: matriz $(40 \times 1619) = (\text{coeficientes} \times \text{quadros})$, gravada como `mfccs.npy` em float32. O coeficiente 0 é a energia do quadro e tem ordem de grandeza muito maior que os demais — por isso aparece em painel separado.