

Reexecução comparativa · BrSD e VCTK a 8 kHz

Os dados e as features estão no HDD. O BrSD contém 400 gravações de 80 locutores; o VCTK usa 21.523 pares de gravações de 108 locutores, em dois microfones. Neste relatório, uma **gravação** (ou **amostra**) é um arquivo de áudio e sua matriz de MFCC. “Enunciado” significa o trecho falado nesse arquivo; não designa uma duração fixa.

Parâmetros de extração

Parâmetro	BrSD	VCTK mic1	VCTK mic2
Taxa nominal do áudio (Hz)	48000	48000	48000
Taxa final (Hz)	8000	8000	8000
VAD	false	false	false
Limiar VAD (dB; desligado)	30	30	30
Pré-ênfase	0.97	0.97	0.97
Coeficientes MFCC	40	40	40
Janela (amostras)	256	256	256

Cinco WAVs do BrSD (106–110) têm taxa nativa de 44,1 kHz; todos os outros áudios usados têm 48 kHz. Cada arquivo é filtrado na própria taxa nativa, antes de ser reamostrado diretamente para 8 kHz.

Filtro anti-aliasing: Butterworth de ordem 8, fase zero, corte de 3,6 kHz. Reamostragem polifásica; salto de 128 amostras (16 ms) para janelas de 256 amostras (32 ms). O limite do modelo é o menor enunciado do respectivo corpus; os dois microfones VCTK compartilham o menor valor observado entre eles.

Comprimento das gravações após a extração

Trilha	Gravações	Mínimo (quadros)	Média	Máximo (quadros)	Gravações extremas
brsd	400	1007	2112.95	7241	mín. L28/E4; máx. L2/E1
vctk8k_mic1	21523	77	223.98	1035	mín. L7/E51; máx. L45/E23
vctk8k_mic2	21523	77	223.98	1035	mín. L7/E51; máx. L45/E23
vctk_combinado	43046	77	223.98	1035	mín. L7/E51; máx. L45/E23

A duração de cada gravação está no arquivo `runs/features/relatorio_comprimentos_8k.csv`. Um quadro avança 16 ms.

Amostras usadas pelas redes

As três redes recebem as mesmas divisões. No BrSD, cada rede usa as cinco leituras por locutor. No VCTK, cada rede do experimento mic1 usa só mic1; cada rede do experimento mic2 usa só mic2. Não há mistura de microfones nestes experimentos.

Trilha	Redes	Partições	Treino por partição	Validação	Teste
brsd	CNN, Temporal CNN, Attention	5	240	80	80
vctk8k_mic1	CNN, Temporal CNN, Attention	5	12913-12914-12915	4304-4305	4304-4305
vctk8k_mic2	CNN, Temporal CNN, Attention	5	12913-12914-12915	4304-4305	4304-4305

Contagens exatas por partição (cada microfone do VCTK tem os mesmos totais):

Corpus	Partição	Treino	Validação	Teste
BrSD	1	240	80	80
BrSD	2	240	80	80
BrSD	3	240	80	80
BrSD	4	240	80	80
BrSD	5	240	80	80
VCTK por microfone	1	12913	4305	4305
VCTK por microfone	2	12913	4305	4305
VCTK por microfone	3	12914	4304	4305
VCTK por microfone	4	12915	4304	4304
VCTK por microfone	5	12914	4305	4304

No BrSD, cada locutor tem 5 gravações: em cada partição, 3 vão para treino, 1 para validação e 1 para teste (60%/20%/20%). O teste gira de E1 a E5 entre as cinco partições; a validação é sorteada entre as outras quatro com semente 42. Cada teste contém o mesmo número de leitura de todos os locutores.

No VCTK, 107 locutores têm 200 gravações por microfone: 120 para treino, 40 para validação e 40 para teste em cada partição (60%/20%/20%). O locutor p362 tem 123 gravações; por isso seus números e os totais variam ligeiramente. Os índices ordenados são distribuídos em cinco grupos intercalados: na partição k, o grupo k é teste, o seguinte é validação e os três restantes são treino. Mic1 e mic2 usam exatamente os mesmos papéis para cada par de gravações.

Trilha	Treino por locutor (mín.-máx.)	Validação por locutor	Teste por locutor
brsd	3-3	1-1	1-1
vctk8k_mic1	73-120	24-40	24-40
vctk8k_mic2	73-120	24-40	24-40

O arquivo `runs/features/relatorio_particoes_8k.csv` informa o papel de **cada** gravação em **cada** partição. As tabelas acima mostram o intervalo de quantidades, não um intervalo contínuo de números de arquivo: os grupos do VCTK são intercalados.

Para os locutores ilustrados, os cinco primeiros índices da partição 1 são:

Trilha	E1	E2	E3	E4	E5
brsd	teste	validacao	treino	treino	treino
vctk8k_mic1	teste	validacao	treino	treino	treino
vctk8k_mic2	teste	validacao	treino	treino	treino

Tamanho das redes

Trilha	Rede	Entrada (MFCC × quadros)	Classes	Parâmetros	Modelo médio (MiB)
brsd	cnn	40 × 1007	80	452.848	5.21
brsd	temporal_cnn	40 × 1007	80	107.536	1.27
brsd	attention	40 × 1007	80	1.730.640	19.93
vctk8k_mic1	cnn	40 × 77	108	341.004	3.93
vctk8k_mic1	temporal_cnn	40 × 77	108	114.732	1.35
vctk8k_mic1	attention	40 × 77	108	1.618.796	18.65
vctk8k_mic2	cnn	40 × 77	108	341.004	3.93
vctk8k_mic2	temporal_cnn	40 × 77	108	114.732	1.35
vctk8k_mic2	attention	40 × 77	108	1.618.796	18.65

Resultados das redes

Trilha	Rede	Acurácia média ± desvio	F1 macro médio	Cinco partições (%)
brsd	cnn	72.25 ± 2.78%	0.646	67.5, 72.5, 75.0, 71.2, 75.0
brsd	temporal_cnn	76.75 ± 4.00%	0.703	71.2, 81.2, 76.2, 81.2, 73.8
brsd	attention	47.50 ± 7.03%	0.388	37.5, 58.8, 43.8, 50.0, 47.5
vctk8k_mic1	cnn	93.09 ± 0.36%	0.931	93.1, 93.1, 93.5, 92.4, 93.2
vctk8k_mic1	temporal_cnn	96.04 ± 0.41%	0.960	96.1, 95.7, 96.6, 96.3, 95.5
vctk8k_mic1	attention	95.06 ± 0.23%	0.951	95.3, 95.3, 94.8, 95.1, 94.8
vctk8k_mic2	cnn	86.21 ± 0.46%	0.862	86.8, 85.7, 85.9, 86.7, 85.9
vctk8k_mic2	temporal_cnn	92.39 ± 0.72%	0.924	91.7, 91.6, 92.6, 93.5, 92.6
vctk8k_mic2	attention	88.76 ± 0.59%	0.887	88.1, 88.6, 89.3, 89.6, 88.3

Os corpora diferem em número de locutores, duração e conteúdo. As acurácias são apresentadas lado a lado como resultados de tarefas fechadas próprias de cada corpus, sem tratá-las como uma medição direta da mesma população.

Cadeia de processamento lado a lado


À esquerda está o locutor 1 do BrSD; nas outras colunas, p225 do VCTK nos microfones 1 e 2. Os números de locutor dos dois corpora não identificam a mesma pessoa. Cada número abaixo é apenas um índice para organizar as figuras: as leituras 1–5 do BrSD são textos diferentes entre si, e também não correspondem aos textos do VCTK. No VCTK, mic1 e mic2 são as duas captações da mesma leitura.

As formas de onda e os MFCCs mostram cada gravação inteira; a escala de tempo varia entre as colunas. A linha vermelha tracejada marca o fim do trecho entregue à rede: os primeiros 1007 quadros (aproximadamente 16.11 s) no BrSD e 77 quadros (aproximadamente 1.23 s) no VCTK. A extração guarda o MFCC completo; o corte ocorre na entrada da rede.

Figura	BrSD: arquivo e duração	VCTK mic1: arquivo e duração	VCTK mic2: arquivo e duração
1	1.wav · 71.54 s	p225_001_mic1.flac · 2.05 s	p225_001_mic2.flac · 2.05 s
2	2.wav · 38.78 s	p225_002_mic1.flac · 3.94 s	p225_002_mic2.flac · 3.94 s
3	3.wav · 32.83 s	p225_003_mic1.flac · 7.59 s	p225_003_mic2.flac · 7.59 s
4	4.wav · 32.18 s	p225_004_mic1.flac · 4.41 s	p225_004_mic2.flac · 4.41 s
5	5.wav · 35.76 s	p225_005_mic1.flac · 6.32 s	p225_005_mic2.flac · 6.32 s


Gravação ilustrativa 1

Gravação ilustrativa 1 · duração inteira; linha vermelha = trecho usado pela rede




Gravação ilustrativa 2

Gravação ilustrativa 2 · duração inteira; linha vermelha = trecho usado pela rede




Gravação ilustrativa 3

Gravação ilustrativa 3 · duração inteira; linha vermelha = trecho usado pela rede




Gravação ilustrativa 4

Gravação ilustrativa 4 · duração inteira; linha vermelha = trecho usado pela rede



Gravação ilustrativa 5

Gravação ilustrativa 5 · duração inteira; linha vermelha = trecho usado pela rede



Fontes dos corpora

- [BrSD, página dos autores.](#)
- [VCTK 0.92, University of Edinburgh DataShare.](#)